BIGDATA TEAM

# HW #01: Inverted Index Lib

## 1. Описание задания

В этом задании вам нужно написать библиотеку по построению инвертированного индекса. Цель задания - приучить себя сначала писать тесты, а уже потом реализацию (TDD).

Правила:

- TDD - сначала тесты, потом реализация;
- Рефакторинг не смешиваем с добавлением функциональности;
- Fuzz/Stress Testing для валидации эффективной реализации.

## 1.1. Инвертированный индекс (Inverted Index)

Инвертированный индекс представляет собой словарь, где ключами являются слова (термы), а значениями - списки идентификаторов документов, в которых указанный терм встречается (см. Рис. 1).

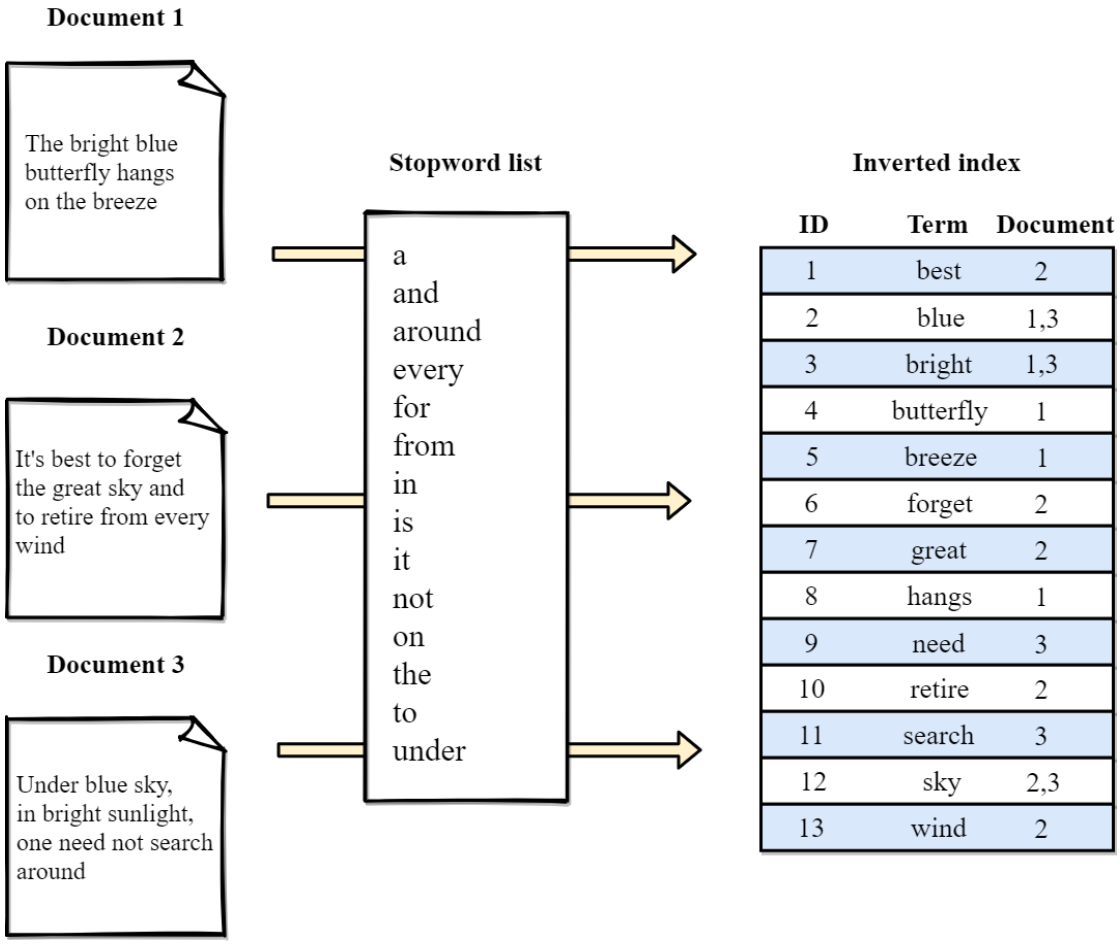

(Рис. 1) Инвертированный индекс

Такая структура позволяет поисковым системам найти страницы в интернете, которые могут быть релевантны пользовательскому запросу. Вам будет предоставлен датасет из документов и по этому датасету нужно построить инвертированный индекс. Библиотека должна предоставить возможность:

1. Считать датасет в оперативную память;
2. Разбить каждый документ на термы (слова);
3. ~~Удалить все стоп-слова;~~[1]
4. Построить инвертированный индекс;
5. Сохранить инвертированный индекс на диск;
6. Загрузить инвертированный индекс с диска;
7. Найти документы, соответствующие заданному поисковому запросу (если в запросе указаны слова “Python” и “code”, то нужно вывести только те документы, которые содержат **оба** этих слова).

На Рис. 1 указаны стоп-слова - это слова, которые встречаются практически в каждом документе. В связи с этим, хранение списка документов, в которых встречается это стоп-слово, не только практически бессмысленно, но еще и болезненно, поскольку хранение этой информации занимает много места в оперативной памяти (или на жестком диске). Бывают и исключения, иногда нужно находить документы на запросы, которые состоят полностью из стоп-слов, например “to be or not to be”. Но решение этой проблемы выходит за рамки нашего курса. Короткий ответ - можно хранить вместо термов биграммы из стоп-слов (например “to be”, “or not” и т.п.) и искать по ним. Длинный ответ - почитайте релевантную литературу по Information Retrieval (информационному поиску).

Любимая книга автора курса на эту тему:

- Christopher D. Manning, Prabhakar Raghavan and Hinrich Schütze, Introduction to Information Retrieval, Cambridge University Press. 2008.
- Доступна для бесплатного скачивания: https://nlp.stanford.edu/IR-book/

## 1.2. Входные данные

**Дамп Википедии**

- Формат: текст
- В каждой строке находятся следующие поля, разделенные знаком табуляции:

[1] В этом задании стоп-слова пока не учитываем, считаем их обычными словами (термами).

1. `INT` - id статьи,
2. `STRING` - текст статьи,

*Пример*:

```
12	Anarchism	Anarchism is often defined as a political philosophy which holds the state to be undesirable, unnecessary, or harmful.
```

## 1.3. Требования к реализации

Возьмите за основу Starter реализации библиотеки:

- github:big-data-team/python-course/.../inverted_index_starter.py

Вам нужно реализовать объявленные функции в Starter'е. Поскольку инвертированный индекс по факту представляет собой словарь, то его хранение на жестком диске рекомендуется выполнить с помощью стандартной библиотеки json (см. json.load(s) и json.dump(s)).

Добавьте пустой test_inverted_index.py и добейтесь уровня покрытия тестами 80% (см. pytest --cov и --cov-branch). При разработке пользуемся идеологией TDD. Примеры тестов:

1. Можно построить инвертированный индекс на основе данных в runtime Python;
2. Можно построить инвертированный индекс на основе данных в файловой системе (используем заготовленный файл);
3. Инвертированный индекс можно выгрузить в файловую систему и из нее загрузиться (используем tmpdir в тестах);

Для гарантии одинаковых результатов, необходимо использовать следующую конструкцию для токенизации статьи на слова:

```
doc_id, content = line.lower().split("\t", 1)
doc_id = int(doc_id)
words = re.split(r"\W+", content)
```

Ожидаемая сигнатура функций:

- `InvertedIndex.query(self, words: List[str]) -> List[int]`
- `InvertedIndex.dump(self, filepath: str) -> None`
- `InvertedIndex.load(cls, filepath: str) -> InvertedIndex`

- `load_documents(filepath: str) -> Dict[int, str]`
  индексы документов кастуем к int'ам
  content не парсим на слова, только строку достаем и отрезаем "\n" в конце строк
- `build_inverted_index(load_documents(filepath: str)) -> InvertedIndex`

После реализации тестов и функционала библиотеки убедитесь, что ваш код является "чистым" (Clean Code):

- изучите PEP-8;
- проверьте качество вашего кода до и после исправления с помощью pylint.

## 2. Рекомендации

Рекомендуем настроить виртуальное окружение Python с нужными версиями библиотек:

1. Если еще не установлено, то установите conda
   https://docs.conda.io/projects/conda/en/latest/user-guide/install/
2. Настройте окружение для разработки на основе README.md курса
   https://github.com/big-data-team/python-course
3. Скачайте необходимые датасеты для выполнения задания
   https://github.com/big-data-team/python-course#study-datasets

## 3. Критерии оценивания

Балл за задачу складывается из:

- **20%** - правильная реализация поиска
- **30%** - возможность выгрузки и загрузки инвертированного индекса на/с жесткого диска
  - запросы типа build и query должны отрабатывать в течение 5 минут на представленном в описании ДЗ датасете
- **40%** - качество покрытия тестами
  - оценка качества проводится автоматически вызовом pytest:
    - `PYTHONPATH=. pytest -v --cov=task_*_inverted_index_lib test_*_inverted_index_lib.py`
    - уровень покрытия тестами должен быть выше 80%
    - проверяем код Python версии 3.7 с помощью `pytest==6.0.1`
    - точная формула: 40% x min([test_coverage / 0.8], 1.0)
- **10%** - поддерживаемость и читаемость кода

- в общем случае см. Clean Code и Google Python Style Guide
- оценка качества будет проводиться автоматическим вызовом pylint:
  - `pylint task_*.py`
  - качество кода должно оцениваться выше 8.0 / 10.0
  - проверяем код Python версии 3.7 с помощью `pylint==2.5.3`
  - точная формула: 10% x min([lint_quality / 8.0], 1.0)

Discounts (скидки и другие акции):

- **100%** за плагиат в решениях (всем участникам процесса)
- **100%** за посылку решения после hard deadline
- **30%** за посылку решения в после soft deadline и до hard deadline
- **5%** за каждую посылку после 2й посылки в день (каждый день можно делать до 2х посылок без штрафа)

лучший балл с 1-й попытки: 100%
лучший балл со 2-й попытки: 100%
лучший балл с 3-й попытки: 95%
лучший балл с 4-й попытки: 90%

Для подсчета финальной оценки **всегда** берется **последняя** оценка из Grader.

## 4. Инструкция по отправке задания

Оформление задания:

- Код задания (Short name): **HW01:InvertedIndex Lib**
- Выполненное ДЗ запакуйте в архив **PY-MADE-2021-Q4**_<Surname>_<Name>_HW#**.zip**, пример -- **PY-MADE-2021-Q4**_Dral_Alexey_**HW01**.zip. (Проверяйте отсутствие пробелов и невидимых символов после копирования имени отсюда.[2]) Если ваше решение лежит в папке my_solution_folder, то для создания архива hw.zip на Linux и Mac OS выполните команду[3]:
  - `zip -r hw.zip my_solution_folder/*`
- На Windows 7/8/10: необходимо выделить все содержимое директории my_solution_folder/ нажать правую кнопку мыши на одном из выделенных объектов, выбрать в открывшемся меню "Отправить >", затем "Сжатая ZIP-папка". Теперь можно переименовать архив.
- Решение задания должно содержаться в одной папке.
- Перед проверкой убедитесь, что дерево вашего архива выглядит так:

[2] Онлайн инструмент для проверки: https://www.soscisurvey.de/tools/view-chars.php
[3] Флаг -r значит, что будет совершен рекурсивный обход по структуре директории

    - `| PY-MADE-2021-Q4_<Surname>_<Name>_HW01.zip`
    - `| ---- task_<Surname>_<Name>_inverted_index_lib.py`
    - `| ---- test_<Surname>_<Name>_inverted_index_lib.py`
    - `| ---- *.txt`[4]
    - При несовпадении дерева вашего архива с представленным деревом, ваше решение не будет возможным автоматически проверить, а значит, и оценить его.
- Для того, чтобы сдать задание необходимо:
    - Зарегистрироваться и залогиниться в сервисе Everest
    - Перейти на страницу приложения: MADE Python Grader
    - Выбрать вкладку Submit Job (если отображается иная).
    - Выбрать в качестве “Task” значение: **HW01:InvertedIndex Lib**[5]
    - Загрузить в качестве “Task solution” файл с решением
    - В качестве Access Token указать тот, который был выслан по почте, если письмо не пришло, пишите в Telegram @bdt_support
- **Перед отправкой задания**, оставьте, пожалуйста, отзыв о домашнем задании по ссылке: https://rebrand.ly/pymade2021q4_feedback_hw. Это позволит нам скорректировать учебную нагрузку по следующим заданиям (в зависимости от того, сколько часов уходит на решение ДЗ), а также ответить на интересующие вопросы.

**Внимание**: если до дедлайна остается меньше суток, и вы знаете (сами проверили или коллеги сообщили), что сдача решений сломана, обязательно сдайте свое решение, прислав нам ссылку на выполненное задание (Job) на почту с темой письма “Short name. ФИО.”. Например: “HW01:InvertedIndex Lib. Иванов Иван Иванович.” Таким образом, мы сможем увидеть какое решение у вас было до дедлайна и сможем его оценить. Пример ссылки:

- https://everest.distcomp.org/jobs/67893456230000abc0123def

Любые вопросы / комментарии / предложения можно писать в телеграм-канал курса или на почту py_made2021q4@bigdatateam.org.

Всем удачи!

[4] Архив с тестовыми данными должен занимать **менее 1МБ** пространства на жестком диске
[5] Сервисный ID: python.inverted_index_lib

## 5. FAQ (часто задаваемые вопросы)

| "You are not allowed to run this application", что делать? |
| --- |
| Если Вы видите надпись "You are not allowed to run this application" во вкладке Submit Job в Everest, то на данный момент сдача закрыта (нет доступных для сдачи домашних заданий, по техническим причинам или другое). Попробуйте, пожалуйста, еще раз через некоторое время. Если Вы еще ни разу не сдавали, у коллег сдача работает, но Вы видите такое сообщение, сообщите нам об этом. |

| Grader показывает 0 или < 0, а отчет (Grading report) не помогает решить проблему |
| --- |
| Ситуации:<br>• система оценивания показывает оценку (Grade) < 0, а отчет (Grading report) не помогает решить проблему. Пример: в случае неправильно указанного access token система вернет -401 и информацию о том, что его нужно поправить;<br>• система показывает 0 и в отчете (Grading report) не указано, какие тесты не пройдены. Пример: вы отправили невалидный архив (rar вместо zip), не приложили нужные файлы (или наоборот приложили лишние - временные файлы от Mac OS и т.п.), рекомендуется проверить содержимое архива в консоли:<br>`unzip -l your_solution.zip`<br><br>Если Вы столкнулись с какой-то из них присылайте ссылку на выполненное задание (Job) в чат курса. Пример ссылки:<br>https://everest.distcomp.org/jobs/67893456230000abc0123def |

## 6. Дополнительные задания (не на оценку)

Расширим функционал библиотеки и для этого предварительно проведем рефакторинг кода:

1. Предоставьте возможность расширять функционал библиотеки инвертированного индекса с помощью Стратегии. Добавьте базовый класс стратегии реализации load/dump инвертированного индекса:
   a. github:big-data-team/python-course/.../storage_policy.py

   Создайте класс JsonStoragePolicy и перенести необходимую функциональность туда. Убедитесь, что все тесты проходят. Следите за качеством кода с помощью pylint (см. https://github.com/big-data-team/python-course#howtos).
2. Реализуйте дополнительные стратегии хранения индекса с помощью библиотек pickle и zlib. Напишите тесты для проверки валидности реализации на основе JsonStoragePolicy.
3. Поделитесь в канале группы, какого сжатия удалось добиться с помощью выбранных библиотек по сравнению с json. Для удобства поиска можно использовать хеш-теги: #inverted_index #compression_challenge